

분류 알고리즘 모델 구축

품질 관리 시스템 개발팀

팀장 : 류재준

팀원 : 김주원

양준혁

이상우



Contents

01

회사 및 팀원 소개

02

목적 및 필요성

03

목표

04

모델 구축 단계

05

기대 효과 및 리스크 관리

06

결론



01

Business Project

회사 및 팀원 소개

저희 창문 징수 회사는 여러 제조업에서 안정적인 품질 관리를 위한 기술들을 개발하고 있습니다.

류재준(팀장) : 시스템 통합

김주원 : 분류 알고리즘 개발

양준혁 : 데이터 확보 및 모델 구축

이상우 : 데이터 확보 및 모델 구축

02

Business Project

목적 및 필요성

지속적인 개선

시스템을 지속적으로 향상시키기 위해 체계적으로 피드백을 하며 이를 통해 개선 사항을 업데이트하는 방식

01

품질 관리

02

정확도와 효율성

육안 검사 대비 정확도와 처리 속도를 확보
분류 알고리즘을 사용하여 정확한 판단이 가능

저비용

고가의 상용 솔루션 대신
저비용 임베디드 장치와
오픈소스 기술로 비용 절감

03

다양한 응용 가능성

의료 분야
농업 분야
물류 및 유통
소비재 제조
안전 관리

04

시스템 목표

라즈베리파이 피코의 불량품과 양품을 실시간으로 분류

정확도
(Accuracy)

95% 이상의 정확도를 달성

처리 속도
(Throughput)

개당 0.7초의 제품 분류 처리

Business Project

04

모델 구축 단계

VERSION 01

YOLO V6 - N

mAP(%) : 54.0
Precison : 0.8
Recall : 0.6
F1 Score : 0.69
Confidence : 0.35
Data set : 131

특이사항 : Hole을 제외한 나머지
클래스들의 detection 성능 저하

모델 개선 방안 : 바운딩 박스 생성 시,
더 균일한 규칙 적용

VERSION 02

YOLO V6 - M

mAP(%) : 81.9
Precison : 1
Recall : 0.93
F1 Score : 0.96
Confidence : 0.44
Data set : 131

특이사항 : V1 모델에서 버전만 업그레이드
시켰을 뿐인데 성능이 확실이 좋아진 것을
확인

모델 개선 방안 : 이전 모델에서와 동일하게
균일한 바운딩 박스의 규칙 적용시키고자 함
- 양질의 Train data set 확보 필요

VERSION 2.1

YOLO V6 - M

mAP(%) : 80
Precison : 1
Recall : 0.93
F1 Score : 0.96
Confidence : 0.35
Data set : 131

특이사항 : "Hole" 클래스를 세분화 하였음
(Up, Down) -> 결과적으로 성능이 저하되는 것을
확인하였으며, 기존 방식으로 되돌렸음
- 컨베이어 벨트를 넘어가는 경우 성능이 떨어짐

모델 개선 방안 : Edge case 를 위한 추가 학습
데이터 필요
- 컨베이어 벨트를 넘어갈 때
- 가로, 세로로 정렬된 이미지
- 양질의 Train data set의 양이 부족하기에
더 많은 데이터 확보 필요

VERSION 03

YOLO V6 - M

mAP(%) : 85.5
Precison : 0.8
Recall : 0.6
F1 Score : 0.69
Confidence : 0.57
Data set : 131

특이사항 : 양질의 학습 데이터 양을 추가함으로
써 모델의 성능이 많이 개선된 것을 확인
- 여전히 Edge case 의 영향을 받는 상황에서 성
능이 떨어지는 것을 확인

모델 개선 방안 : Edge case에 해당하는 컨베이어
벨트 관련 학습 데이터를 충분히 확보할 예정

Business Project

모델 구축 단계



VERSION 04

YOLO V6 - M

mAP(%) : 84.8
Precison : 0.99
Recall : 0.95
F1 Score : 0.97
Confidence : 0.37
Data set : 618

특이사항 : 학습 데이터를 추가하여 모델을 학습

- 지표상으로는 모델의 성능에 큰 변화가 없지만
동일한 Test data set으로 검증을 해본 결과
성능 향상

모델 개선 방안 : 실제 공정 환경과 동일한 환경에서
의 양질의 Train data set이 많이 필요

- 불량품을 양품으로 인식 (미검) 하는 부분에 대
여 디테일한 분류 알고리즘의 개선이 필요

VERSION 4.1

YOLO V6 - L

mAP(%) : 85.1
Precison : 0.99
Recall : 0.95
F1 Score : 0.97
Confidence : 0.4
Data set : 618

특이사항 : 모델의 버전을 업그레이드
(M → L)

- M 모델과의 비교에서는 지표상으로 큰 차이를 나타내
지는 않지만 Test data set으로 검증을 해본 결과 성능
이 살짝 좋아진 것을 확인

모델 개선 방안 : 실제 공정 환경과 동일한 환경에
서의 양질의 Train data set이 많이 필요

- 불량품을 양품으로 인식 (미검) 하는 부분에 대
하여 디테일한 분류 알고리즘의 개선이 필요

FINAL VERSION

YOLO V6 - L

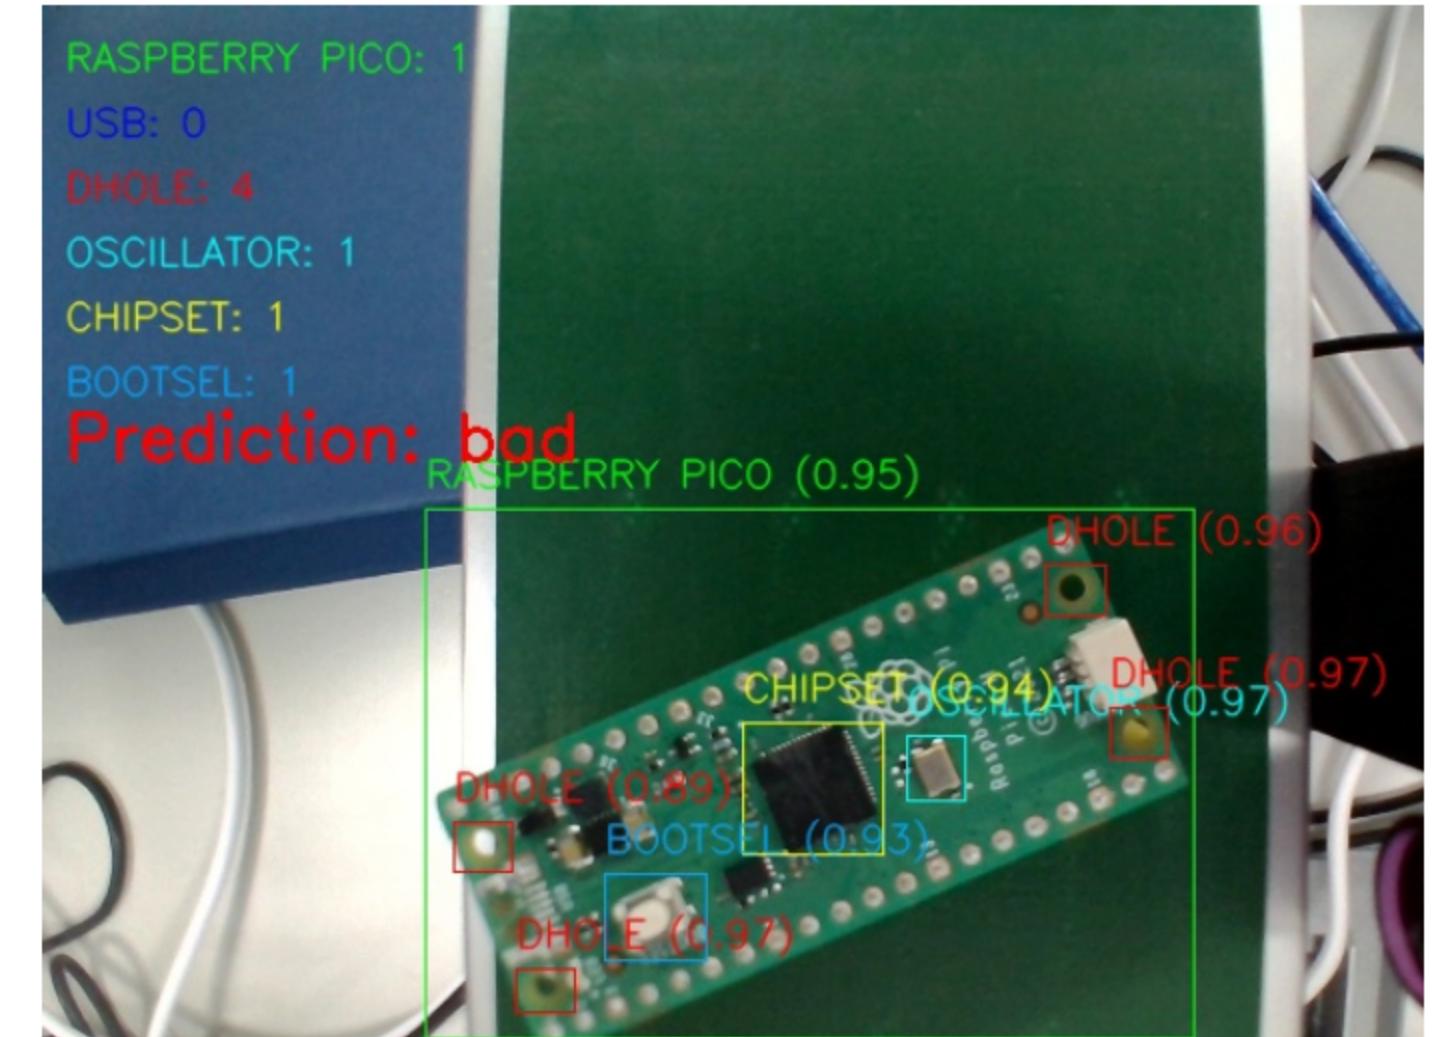
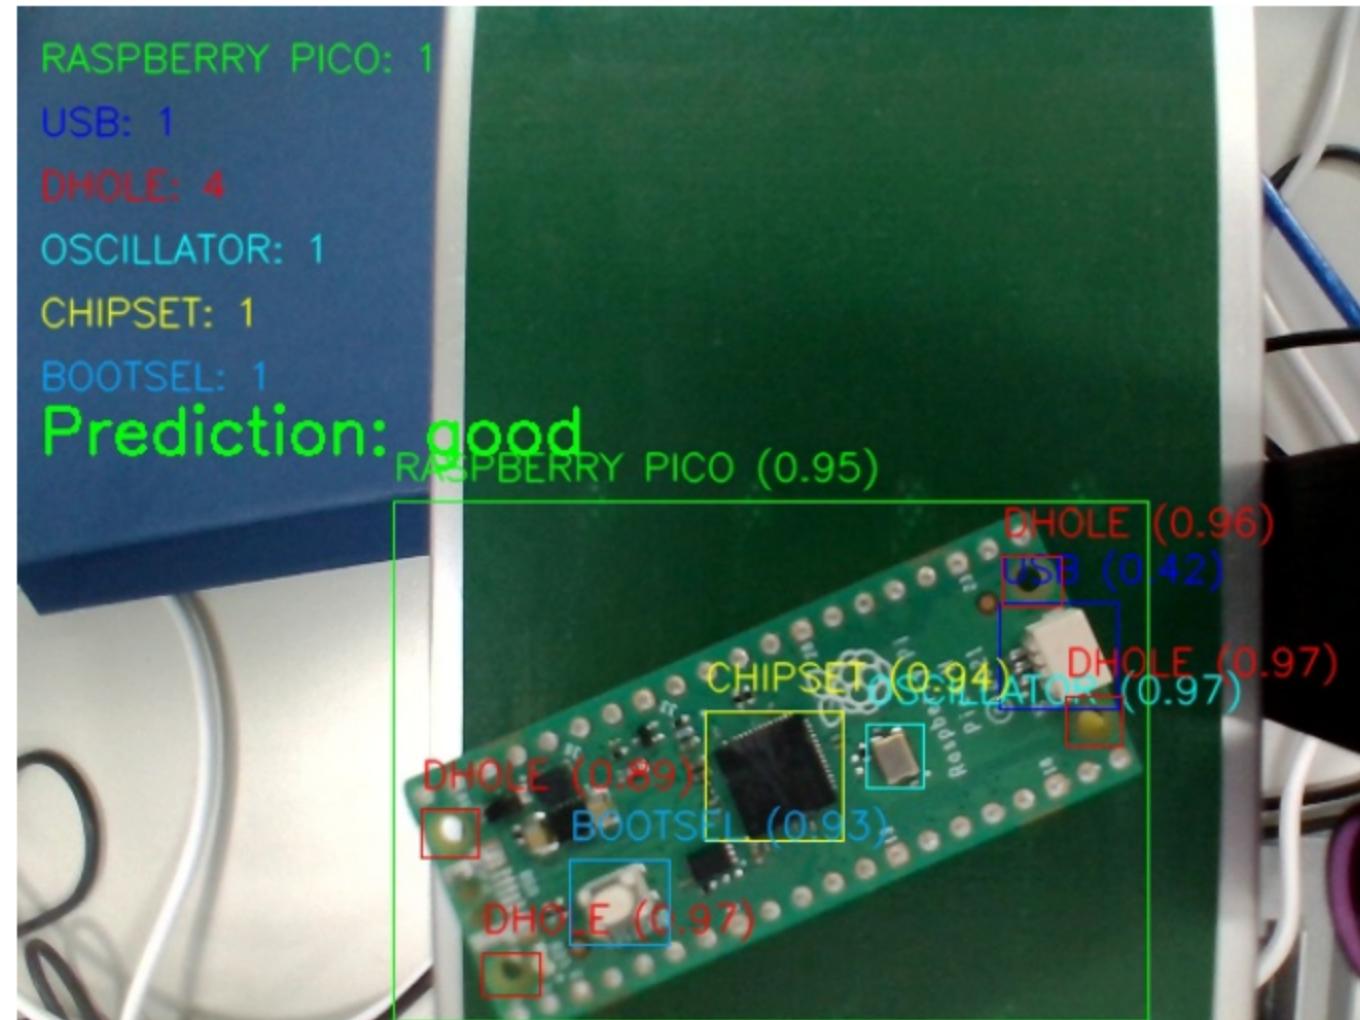
mAP(%) : 92.3
Precison : 1
Recall : 0.99
F1 Score : 0.99
Confidence : 0.34
Data set : 1084

특이사항 : 양질의 학습 데이터를 많이 확보하여 모델을 학습시킨 결과
가장 좋은 성능을 나타내는 모델 구축

- 불량품을 양품으로 판단(미검)하거나, 양품을 불량품을 판단 (과검)
하는 부분에서 디테일한 분류 알고리즘을 적용시켜 문제를 개선

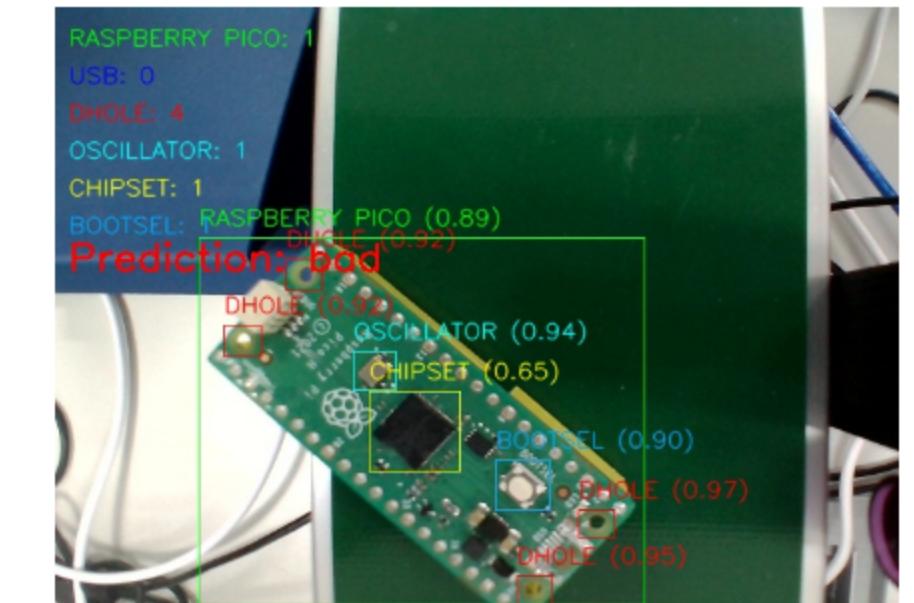
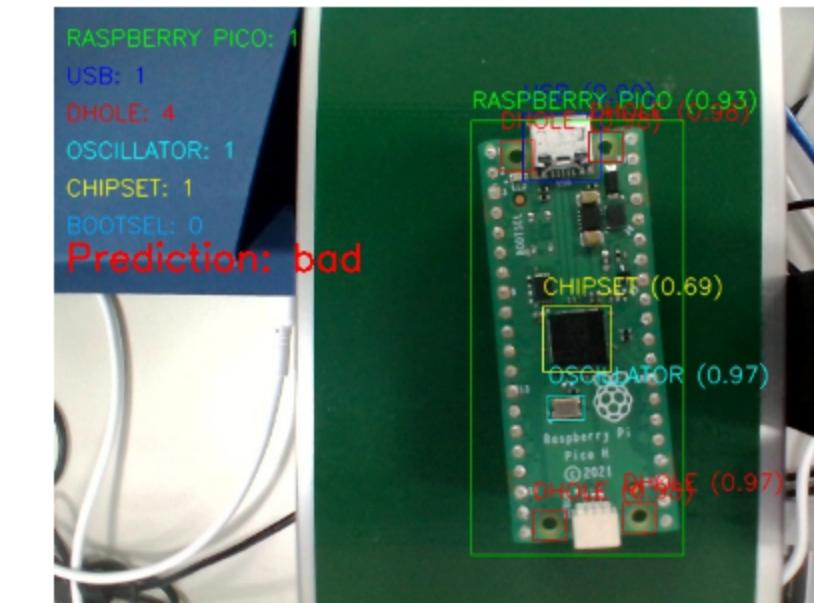
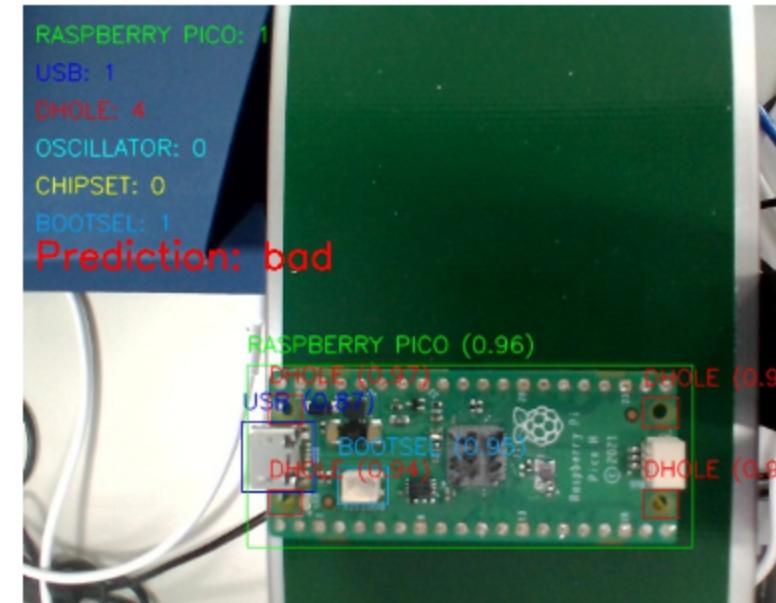
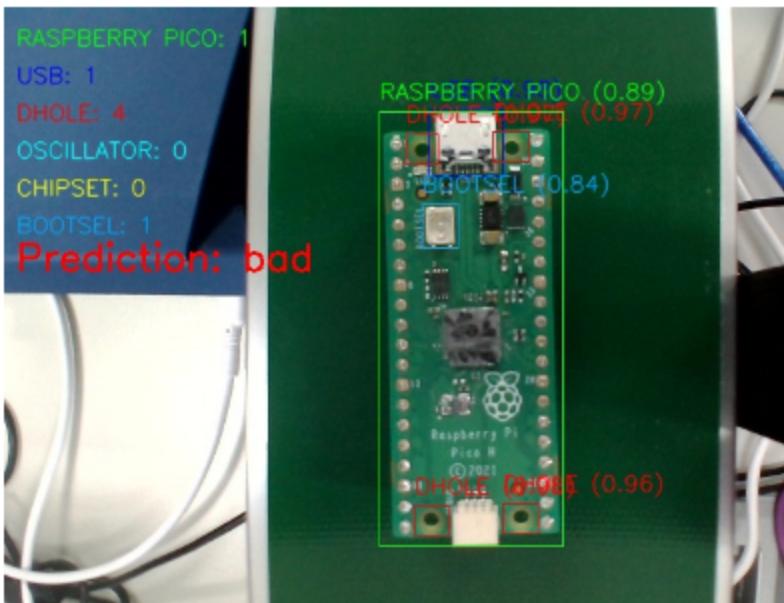
모델 개선 방안 : 학습 데이터셋이 더 확보된다면
양질의 모델을 구축 가능
(꾸준한 업데이트 가능)

모델 성능



Final Version에서 불량품인데 양품으로 인식하는 문제 (미검) 가 1 case 생김
이는 임계값을 설정하는 알고리즘을 사용하여 해결하였음 (good이라고 판단했지만,
특정 컨피던스 값을 넘지 않으면 불량으로 판단)

모델 성능



Final version 검출 예시 (200개의 Test set 사용)

=> 150개의 양품, 50개의 불량품 이미지 데이터로 검증한 결과 (Confusion matrix)

	good	bad	Precision (정밀도 : $TP / (TP + FP)$) = $144 / 144 = 1$
good	144 (TP)	6 (FN)]	Recall (재현율 : $TP / (TP + FN)$) = $144 / 150 = 0.96$
bad	0 (FP)	50 (TN)]	F1 score ($2 * (P * R) / (P + R)$) = 0.98

=> 미검: 0개 (0 %)

=> 과검: 6 개 (4 %)

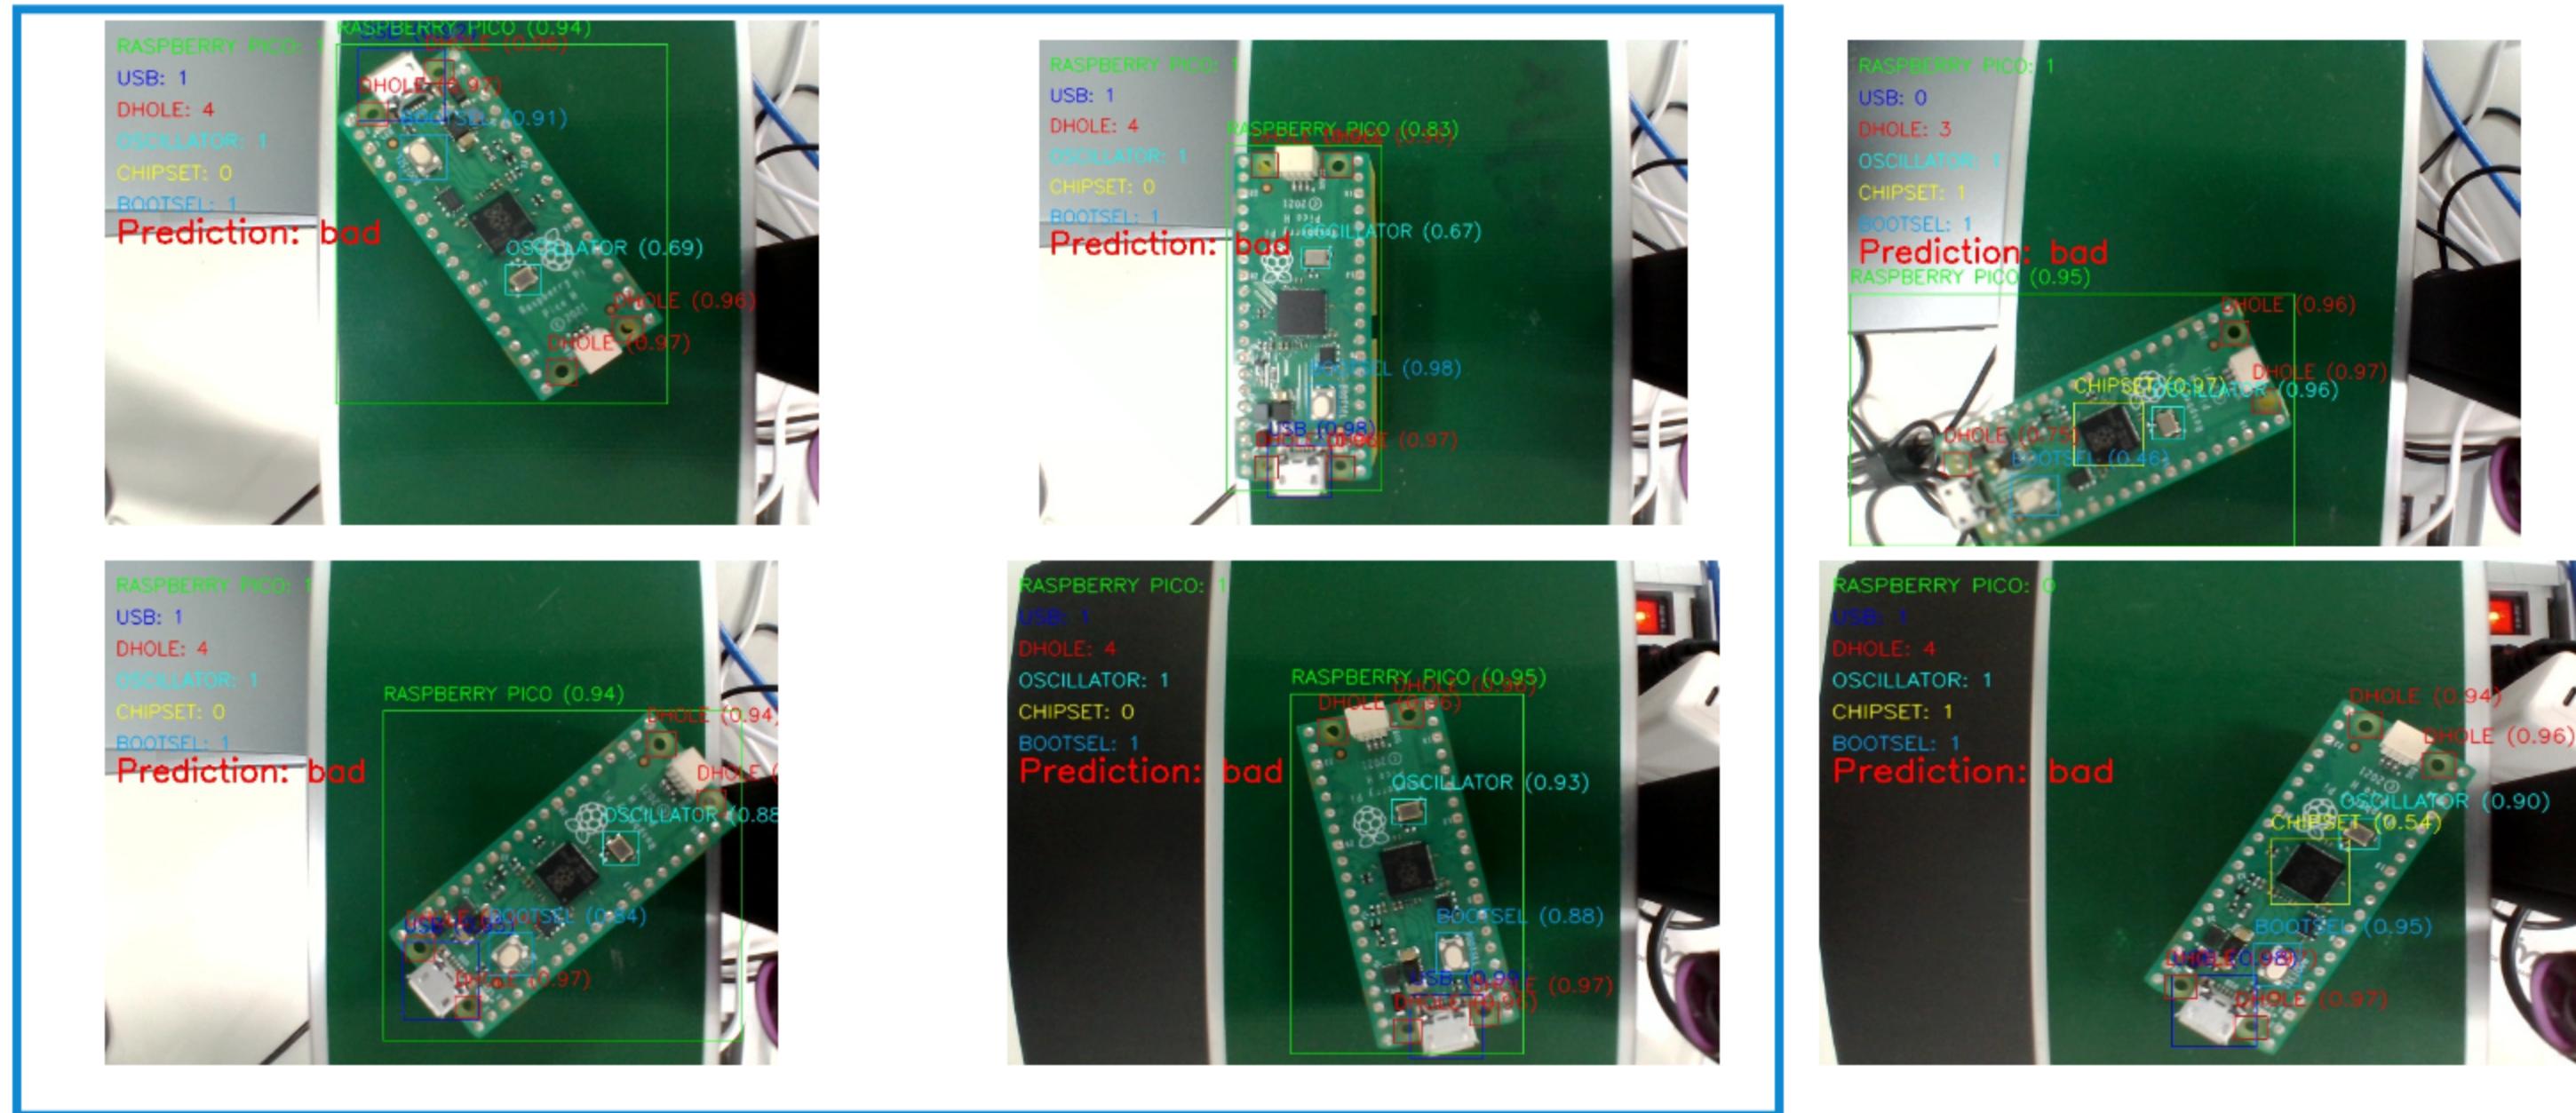
=> 정확도 : 0.97 (97 %)

- 불량품을 양품으로 판별하는 문제가 없음, 즉 제조 과정에서 가장 중요하게 생각하는 미검이 0% 임

- 검출시간 : 1개당 0.7초에 검출할 수 있으며, 1시간에 약 5150개를 검출가능

Business Project

모델 성능



양품이지만 불량품으로 판별한 경우 (과검) 6개의 케이스

- 1) 칩셋을 인식하지 못하는 경우 : 4개
 - 2) 피코를 인식하지 못하는 경우 : 1개
 - 3) USB와 Hole을 인식하지 못하는 경우 : 1개 (화질이 흐리며, Edge case임)

기대 효과

프로젝트 성공 시 예상되는 성과와 이익

양품과 불량품의 인식 과정 단축 가능

- 1개의 제품을 검사할 때 실제 사람
이 분류한다면 약 4~7초 가량 소
모되며, 본 시스템을 적용시켰을
경우 약 0.7초 만에 분류가 가능함
(약 6배~10배의 속도차이)

소프트웨어 및 하드웨어 구축 비용을
제외한 단순 노동 인건비 절약 가능

장단기 효과

단기: 검사 인력 감소, 처리 효율 증가,
작업자 피로도 최소화

장기: 데이터 축적으로 시스템 학습 및 성
능 향상을 향상시켜 완전 무인화와 자동화
운영이 가능

리스크 관리

예상되는 리스크와 대응 계획

1) AI 모델 학습 데이터 편향

• 리스크: 모델이 충분히 다양한 데이터로 학습되지 않았을 경우 특정 결함 유형을 정확히 탐지하지 못할 가능성이 있음

- 대응 계획:

- 다양한 데이터셋(조명 조건, 각도, 불량 유형 등)을 확보하여 학습

- 지속적으로 데이터를 추가 수집하고 모델을 주기적으로 재 훈련

2) 검사 환경의 변화

리스크: 조명, 온도, 먼지 등 검사 환경의 변화로 인해 인식률이 떨어질 가능성이 있음

대응 계획:

- 환경 변화에 강인한 이미지 전처리 기술 적용 (예: 조명 보정 알고리즘)

- 환경에 적합한 학습데이터 확보 후 모델 파라미터 설정

리스크 발생 시 대처 방안

1) AI 모델 오류 발생 시

대처 방안:

- 임시로 이전 모델 버전으로 롤백하여 운영 안정화
- 잘못 분류된 데이터를 분석해 추가 학습에 반영

2) 환경 요인으로 인한 성능 저하

대처 방안:

- 검사 환경을 점검하고 조명 등 외부 요인 조정.
- 긴급 상황에서는 추가 전처리 단계를 적용하거나, 문제 해결 전 수작업 병행.

결론

본 프로젝트는 양품과 불량품을 자동으로 판별하는 시스템을 구현함으로써, 제조업의 품질 관리 프로세스를 혁신적으로 개선할 수 있는 가능성을 제시합니다. 특히, 저비용으로도 구현 가능한 “높은 정확도와 효율성”을 가진 솔루션을 통해, 중소규모 제조업체도 쉽게 도입할 수 있는 접근성을 확보했습니다.

- 주요 성과:

- 속도와 정확도: 기존 육안 검사 대비 6~10배 빠른 속도로 양품/불량품 분류, 97% 이상의 높은 정확도 달성
- 경제적 이점: 인건비 절감과 더불어 생산 공정 효율성을 극대화
- 확장 가능성: 특정 하드웨어에 제한되지 않고, 다양한 산업 분야(의료, 농업, 물류 등)에서도 활용 가능한 범용 시스템

- 본 프로젝트의 의의:

- 자동화 품질 관리의 접근성 향상: 중소규모 제조업체도 경제적으로 도입 가능
- 데이터 기반 개선: 축적된 데이터를 활용해 지속적으로 시스템 성능을 향상
- 범용성 확보: 다양한 응용 환경과 문제에 적용 가능한 확장 가능한 솔루션

- 향후 계획:

- 시스템 고도화: AI 모델 학습 데이터 확대 및 성능 최적화
- 산업 확장: 의료, 소비재 제조 등 새로운 산업군으로 적용 사례 확대 예정
- 실제 적용 테스트: 실제 제조 라인에 배치하여 안정성과 효과를 검증할 예정